

Лабораторная работа №1

Тема: NumPy, векторизация, бродкастинг и линейная алгебра

Данные: `olist_order_items_dataset.csv`, `olist_products_dataset.csv`.

Введение

Вам поручено оптимизировать ядро системы расчетов в бразильском маркетплейсе **Olist**. Поскольку транзакций миллионы, использование стандартных циклов Python недопустимо по соображениям производительности.

Задание 1: Битва производительности (Loops vs NumPy)

Необходимо рассчитать итоговую стоимость позиции в заказе с учетом налога и динамической скидки на основе данных `olist_order_items_dataset.csv`.

Логика расчета:

$$\text{Total Price} = (\text{price} \times (1 - \text{discount})) + \text{freight_value}$$

Условия скидки:

- Если `price > 500 BRL` — 15%;
- Если `price > 100 BRL` — 10%;
- В остальных случаях — 0%.

Реализация:

- Реализация А:** Функция на чистом Python, использующая итерацию по спискам.
- Реализация Б:** Векторизованный расчет с использованием `np.select` или булевых масок NumPy.

Профилирование: Сравните скорость выполнения с помощью магической команды `%timeit`. Ожидаемое ускорение — более чем в 50 раз.

Задание 2: Интеллектуальный фильтр и Fancy Indexing

Работа с файлом `olist_order_items_dataset.csv` для поиска аномалий.

- Булево индексирование:** Выделите все записи, где цена (`price`) выше среднего значения по датасету более чем на 3 стандартных отклонения (3σ).
- Fancy Indexing:** Создайте массив индексов для 100 случайных заказов и выберите соответствующие им строки из таблицы, используя только средства NumPy.

Задание 3: Бродкастинг (Объемный вес и логистика)

Работа с файлом `olist_products_dataset.csv`.

1. **Векторизация:** Рассчитайте объемный вес товаров по формуле:

$$V_{weight} = \frac{L \times H \times W}{6000}$$

Используйте колонки `product_length_cm`, `product_height_cm`, `product_width_cm`.

2. **Broadcasting:** Создайте матрицу цен товаров размерностью (1000×5) , где 5 — количество складов. Умножьте всю матрицу на вектор региональных коэффициентов размера 5 за одну операцию без использования циклов.

Задание 4: Векторное сходство (Линейная алгебра)

Реализация простейшего движка рекомендаций на основе характеристик товаров.

1. **Подготовка:** Создайте матрицу признаков (вес, длина, высота, ширина) для первой тысячи товаров. Выполните нормализацию данных.
2. **Матричные операции:** Реализуйте расчет косинусного сходства (*Cosine Similarity*) между вектором конкретного «выбранного» товара и всей матрицей признаков.
3. **Инструментарий:** Используйте только матричное умножение (`@` или `np.dot`) и `np.linalg.norm`. Использование внешних библиотек (например, `scikit-learn`) запрещено.

Требования к сдаче

- ✓ **Zero Loops:** В расчетных ячейках полностью отсутствуют циклы `for` и `while`.
- ✓ **Profiling:** В ноутбуке представлены результаты выполнения `%timeit` для Задания 1.
- ✓ **Vector Thinking:** Все операции в Задании 4 выполнены в матричном виде.