

Лабораторная работа №2

Тема: Структуры Pandas, чтение сложных форматов, строковые операции и борьба с пропусками

Данные: `olist_orders_dataset.csv`, `olist_order_reviews_dataset.csv`, `olist_customers_dataset.csv`

Задача

Данные из разных систем маркетплейса часто приходят с «шумом»: некорректные типы дат, пропуски в текстах отзывов и избыточная информация. Ваша цель — превратить этот набор файлов в чистый и типизированный массив данных для дальнейшего анализа.

Задание 1: Эффективная загрузка и типизация

Файлы заказов содержат много временных меток, которые Pandas по умолчанию считает как строки.

1. **Загрузка:** Считайте `olist_orders_dataset.csv`, выбрав только необходимые столбцы: `order_id`, `customer_id`, `order_status` и все колонки со временем (*timestamps*).
2. **Типизация:** Преобразуйте все столбцы с датами в формат `datetime64` за одну операцию (используйте `pd.to_datetime` с параметром `errors='coerce'`).
3. **Память:** Измерьте объем памяти, который занимает столбец `order_status`, и объясните, почему его выгодно перевести в тип `category`.

Задание 2: Очистка текстовых данных и пропусков

Используйте файл `olist_order_reviews_dataset.csv`. В нем много пустых полей, так как не все клиенты пишут развернутый отзыв.

1. **Обработка пропусков:**
 - Пропуски в `review_comment_title` заполните строкой "No title".
 - Пропуски в `review_comment_message` заполните строкой "No message".
2. **Векторизованные строки:** С помощью методов `.str` приведите все отзывы к нижнему регистру и удалите спецсимволы (переносы строк `\n` и `\r`).
3. **Дубликаты:** Найдите и удалите дубликаты отзывов, оставив только самые свежие (по `review_creation_date`) для каждого `order_id`.

Задание 3: Парсинг и фильтрация (Data Discovery)

Используйте файл `olist_customers_dataset.csv`.

1. **Парсинг:** Из столбца `customer_city` выделите первую букву и создайте новый столбец `city_initial`.

2. **Инструментарий:** С помощью метода `.loc` сделайте выборку всех клиентов из штата "SP" (Сан-Паулу), у которых почтовый индекс начинается на "01".
3. **Индексация:** Установите `customer_id` в качестве индекса и продемонстрируйте выборку конкретного клиента по его хеш-коду.

Требования к сдаче

- **No NaNs:** В итоговых таблицах не должно остаться необработанных NaN в ключевых колонках (отзывы, статусы).
- **Correct Dtypes:** Все временные метки должны иметь тип `datetime64`, а не `object`.
- **Vectorized Ops:** Для очистки строк использованы методы `.str`, а не циклы по строкам таблицы.