

Лабораторная работа №3

Тема: Слияние таблиц, обработка дубликатов при связях «один-ко-многим», когортный анализ и оконная агрегация в сводных таблицах

Данные: `olist_orders_dataset.csv`, `olist_order_items_dataset.csv`, `olist_products_dataset.csv`, `olist_customers_dataset.csv` и `product_category_name_translation.csv`.

Контекст задачи

Слепое объединение таблиц в e-commerce часто приводит к искажению финансовых метрик. Ваша задача — собрать надежную витрину данных, обойти ловушки задвоения суммы доставки и провести глубокую сегментацию пользователей.

Задание 1: Сборка ядра и «Ловушка доставки» (Merging & Data Integrity)

При объединении заказа (*orders*) с его товарами (*order_items*) возникает связь «один-ко-многим».

- **Базовое слияние:** Соберите все 5 таблиц в единый DataFrame. Учтите, что не все португальские категории имеют перевод на английский — такие записи не должны пропасть (обработайте их и назовите "unknown").
- **Ловушка freight_value:** В таблице *order_items* стоимость доставки (*freight_value*) указана для каждой позиции в заказе. Если в заказе 3 одинаковых товара, сумма доставки в чеке может быть задвоена.
- **Подзадача:** Рассчитайте корректную общую стоимость каждого уникального заказа (*Total Order Value*) с учетом цены товаров и корректной суммы доставки.
- **Бизнес-фильтр:** Для дальнейшего финансового анализа оставьте только те заказы, которые были реально доставлены (*order_status* == 'delivered'). Обоснуйте в комментариях, почему отмененные заказы сломают нам расчет выручки.

Задание 2: RFM-анализ (Recency, Frequency, Monetary)

Маркетингу нужна не просто группировка по тратам, а классическая RFM-матрица.

1. **Агрегация (R, F, M):** Для каждого уникального клиента (*customer_unique_id*) рассчитайте:
 - **Recency:** Количество дней с момента последней покупки до «сегодняшнего дня». (За «сегодня» возьмите максимальную дату покупки во всем датасете + 1 день).
 - **Frequency:** Количество уникальных заказов (а не купленных товаров!).
 - **Monetary:** Суммарная выручка с клиента (опирайтесь на корректный расчет из Задания 1).

2. **Скоринг:** С помощью `pd.qcut` (или `pd.cut` для Frequency, так как там могут быть узкие диапазоны) присвойте каждому параметру оценку от 1 до 4 (где 4 — лучший показатель).
3. **Сегментация:** Склейте оценки в одну строку (например, клиент с R=4, F=4, M=4 получит код "444" — это «Чемпионы»). Выведите топ-5 штатов, где проживает больше всего «Чемпионов».

Задание 3: Проникновение категорий (Advanced Pivot Tables)

Бизнесу нужны не абсолютные цифры, а доли рынка.

1. **Матрица:** Постройте сводную таблицу выручки, где строки — штаты (`customer_state`), столбцы — топ-10 категорий товаров.
2. **Нормализация (Доли):** Преобразуйте абсолютные значения выручки в проценты. Таблица должна показывать, какую долю в выручке конкретного штата занимает каждая категория (сумма по строке для топ-10 должна равняться 100%).
Подсказка: используйте метод `.div(axis=0)`.
3. **Анализ аномалий:** Найдите штат, в котором доля категории "health_beauty" аномально высока по сравнению со средним показателем этой категории по всей стране.

Задание 4: Когортный анализ удержания (Retention Rate)

Нужно понять, возвращаются ли к нам клиенты после первой покупки.

1. **Месяц когорты:** Для каждого клиента определите месяц его самой первой покупки (*Cohort Month*).
2. **Индекс активности:** Для каждого заказа вычислите «Индекс месяца» (*Month Index*) — сколько полных месяцев прошло с момента первой покупки этого клиента (0 — тот же месяц, 1 — следующий и т.д.).
3. **Когортная матрица:** Используя `groupby` и `pivot_table`, постройте матрицу удержания. В строках — месяцы когорт, в столбцах — *Month Index* (0, 1, 2...), в ячейках — количество уникальных активных клиентов.
4. **(Опционально):** Переведите абсолютные значения в проценты, где размер когорты в *Month 0* принимается за 100%.

Требования к сдаче

- [] **Data Granularity:** Продемонстрировано четкое понимание разницы между уровнем строки заказа (`order_id`) и уровнем позиции товара (`order_item_id`).
- [] **Handling Nulls:** Осмысленная стратегия работы с пропущенными переводами категорий (без «тупого» `dropna`).
- [] **Elegant Pandas:** Избегание цепочек из множества промежуточных датафреймов. Использование `.groupby().agg()` с передачей словаря для расчета разных метрик за один проход.