

# Лабораторная работа №4

Тема: `DatetimeIndex`, бизнес-календари, регулярные сетки, скользящий Z-score и защита от утечек данных (Data Leakage)

Данные: `olist_orders_dataset.csv`, `olist_order_items_dataset.csv`.

## Задача

Слепое применение временных функций ведет к искажениям: игнорирование выходных дней ломает оценку логистики, а пустые дни без продаж искажают скользящие средние. Ваша задача — рассчитать метрики эффективности складов (SLA), восстановить непрерывность данных и подготовить временные признаки для будущей ML-модели предсказания спроса.

## Задание 1: Бизнес-календарь и нарушения SLA

Оценивать скорость доставки в обычных днях некорректно, так как логистика не работает по выходным.

- Типизация и индексы:** Преобразуйте даты в `datetime64`. Создайте копию датасета, где индексом будет выступать `order_purchase_timestamp`.
- Рабочие дни (Business Days):** Рассчитайте `delivery_time_working_days` — количество исключительно рабочих дней между подтверждением заказа (`order_approved_at`) и его доставкой (`order_delivered_customer_date`).  
*Подсказка: изучите `np.busday_count` или `pd.bdate_range`.*
- Анализ просрочек (SLA Breach):** Сравните фактическую дату доставки с обещанной (`order_estimated_delivery_date`).
  - Создайте булеву маску `is_delayed` (доставлено позже срока).
  - Найдите месяц с максимальным процентом просроченных заказов.

## Задание 2: Регуляризация сетки и интрадэй-паттерны

В логах бывают дни, когда не было продано ни одного товара. Обычный `groupby` просто пропустит эти дни, что сломает алгоритмы прогнозирования.

- Непрерывная сетка:** Посчитайте суммарную выручку по дням. Найдите минимальную и максимальную даты в датасете. Постройте полную сетку дат (`pd.date_range`) и выполните `reindex` вашего сгруппированного ряда. Заполните образовавшиеся NaN нулями.
- Пиковые часы со сдвигом:** С помощью сводной таблицы (`pivot_table`) или двойной группировки найдите час пик продаж для каждого конкретного дня недели (например: Понедельник — 14:00, Суббота — 21:00).

## Задание 3: Динамические бейзлайны и локальные аномалии

Глобальное отклонение в  $2\sigma$  или  $3\sigma$  не работает для бизнеса с растущим трендом.

1. **Кумулятивные метрики (YTD):** Рассчитайте кумулятивную выручку с начала года (*Year-To-Date*) для каждого дня, используя метод `.expanding()`.
2. **Скользящий Z-score:** Для поиска аномалий реализуйте динамический порог. Вычислите 30-дневное скользящее среднее ( $\mu_{t-30}$ ) и 30-дневное скользящее стандартное отклонение ( $\sigma_{t-30}$ ). Рассчитайте скользящий Z-score по формуле:

$$Z_t = \frac{x_t - \mu_{t-30}}{\sigma_{t-30}}$$

Найдите даты, где  $Z_t > 3$  (локальные аномальные всплески).

## Задание 4: Лаги и защита от Data Leakage (ML Prep)

При конструировании признаков самая частая ошибка — использовать данные из будущего.

1. **Безопасные окна:** Рассчитайте признак `revenue_last_7d` (выручка за предыдущие 7 дней). Данные за текущий день не должны входить в эту сумму. Скомбинируйте методы `.shift()` и `.rolling()`.
2. **Относительный темп (WoW Growth):** Рассчитайте *Week-over-Week* рост выручки. Сравните выручку за последние 7 дней (`revenue_last_7d`) с выручкой за аналогичный период недель ранее (`revenue_prev_7d`). Выведите топ-3 дня с самым сильным падением выручки.

## Требования к сдаче

- [ ] **Time Integrity:** Продемонстрировано умение бороться с пропущенными датами через `reindex` или `asfreq`.
- [ ] **Zero Data Leakage:** В оконных функциях строго доказано, что целевая переменная (день  $T$ ) не участвует в расчете признаков (использован `.shift()`).
- [ ] **Advanced Metrics:** Использование `expanding` и расчет *Business Days* выполнены векторизованно, без циклов и `.apply()`.